

Layer 1 = 숫자로는 안 걸리지만 뭔가 미심쩍은 것**을 LLM이 읽고 판단함(5각도)

	Layer 0 (코드)	Layer 1 (LLM)
고점추격	ret_5d $\geq$ 15% $\rightarrow$ 무조건 컷 (명백)	ret_5d 11%처럼 애매할 때, 다른 정황 같이 보고 "이건 추격 같다" 판단
방식	숫자 넘으면 자동 컷	숫자론 안 걸리지만 맥락상 의심되면 반박

① 가짜 합의(disclosure_ref 확인 대기)

정리 — Layer 1 구조 (1번 작업)

Layer 1 = LLM 반박층

역할: Layer 0(명백 컷) 통과한 회색지대 신호를
LLM이 5각도 체크리스트로 논리 공격

작동:

입력: 은미님 payload + 원본 신호 데이터
지시: "적대적 Critic으로서 5각도로 공격하라"
출력: 각도별 반박 여부 + 이유 + 종합 의견

5각도 (LLM의 체크리스트):

- ① 가짜 합의 ② 선반영·추격 ③ 미검증 촉매
- ④ 확산 캘리브레이션 ⑤ 신호 신선도

Layer 0와의 관계:

Layer 0 = 명백한 것 숫자로 즉시 컷
Layer 1 = 애매한 것 LLM이 논리로 판단
 $\rightarrow$ 겹침 아니라 역할 분담 (명백 $\rightarrow$ 코드, 애매 $\rightarrow$ LLM)

가짜 합의 — Layer 1 지시서 완성본

[① 가짜 합의 (신호 독립성)]

- 1. 뭘 의심하는가
signal_consensus가 높다(N개 동의)지만, 진짜 독립된 N개인가
아니면 같은 사건 하나에 여러 신호가 반응한 걸 여러 개로 센 건가
- 2. 뭘 보고 판단
 - 은미: signal_consensus, bull_case
 - 원본: tb_news.event_type, tb_disclosure.event_type
 - [A] tb_news.disclosure_ref (있으면 — 뉴스가 그 공시를 가리키나)
 - [B] 각 신호의 시각 (collected_at / created_at)
- 3. 어떻게 따지나

[A] disclosure_ref 있으면 (강한 판정):

뉴스의 disclosure_ref가 공시를 직접 가리키면

→ 뉴스 = 공시 보고 쓴 것 = 독립 아님 (같은 사건)

[B] disclosure_ref 없으면 (보조 판정):

공시·뉴스의 event_type이 같고(예: 둘 다 "ma")

+ 발생 시각이 비슷하면

→ 같은 사건일 가능성 높음 (독립성 의심)

공통 결론: 겹보기 N개 동의 → 실질 독립 근거 몇 개?

■ 4. 뭐라고 답하나

"가짜 합의: [있음/없음]"

근거: 예) 공시·뉴스 모두 ma 사건, disclosure_ref로 연결

→ 겹보기 3개지만 실질 독립 2개 (사건1 + 기술1)"

★ 은미님 확인: disclosure_ref 컬럼이 최종 확정되는지 (창육이랑 협의 결과)

— 확정되면 [A] 강한 판정 사용, 안 되면 [B]로만 작동

② 선반영·추격=공격형이랑 부딪혀서 호재 신선도로 판단한다 들

[② 선반영·추격]

■ 1. 뭘 의심하는가

bull_case의 호재가 이미 가격에 반영된 뒤(늦은 진입) 아닌가.
Layer 0 숫자 컷은 통과했지만, 맥락상 "다 오른 뒤 추격"인가.

■ 2. 뭘 보고 판단

- 은미: bull_case (무슨 호재인지), current_price
- 원본: tb_disclosure/tb_news의 event_type + 발생 시각
tb_technical: ret_5d, ret_20d, high_252_ratio, close(어제종가)

■ 3. 어떻게 따지나

- 호재(공시/뉴스)가 언제 발생했나?
- 그 시점 이후로 가격이 이미 많이 올랐나?
(호재 후 ret_5d/ret_20d가 큰가, current_price가 호재 전보다 훌쩍 높은가)
- high_252_ratio가 1.0 근처(신고가)인가?
→ 호재는 이미 며칠 전, 그 뒤 가격 급등, 신고가 근처
= "선반영 + 늦은 추격" 의심
→ 호재가 방금, 가격 아직 안 움직임 = 추격 아님 (오히려 기회)

■ 4. 뭐라고 답하나

"선반영·추격: [있음/없음]
근거: 예) 인수 공시 3일 전, 이후 +18% 급등, 신고가 근처
→ 호재 이미 반영, 지금 진입은 추격성"

호재가 아직 유효한가 vs 이미 소비됐다. 이게 공격형과 균형 맞추는 핵심

★ 확인: tb_news/tb_disclosure의 시각 컬럼이 "호재 실제 발생 시각"인지 "수집 시각"인지 (선반영 판단에 필요)

③ 미검증 측매

****컬럼 = 표의 세로 항목, "무슨 정보를 담는 칸이냐"****

근거는

뉴스분석 20,21번인

source_trust(llm 읽고 해석하여 매기는 점수) NUMERIC 0~1 ★ 이 뉴스 출처를 얼마나 믿나. LLM이 내용까지 보고 판단 ✓ 루머·펌프 방어 핵심. 산출: $\Sigma(\text{trust} \cdot w) / \text{tw}$ · LLM·해석·사후

grade_score(출처보고 매기는 점수) NUMERIC 0~1 ★ 출처를 코드가 도메인만 보고 매긴 등급(로이터1.0·미등록0.6·차단0). 사전 관문 ✓ source_trust와 별개 측: $\text{grade} = \text{코드} \cdot \text{사전} / \text{trust} = \text{LLM} \cdot \text{사후}$. 산출: $\Sigma(\text{GRADE_SCORE} \cdot w) / \text{tw}$

즉 은미 JSON은 은미가 요약해서 준 것 > 은미님 주장임

규칙

grade_score는 이미 값이 딱 정해져 있어 (문서 06번 #21):

로이터 = 1.0

미등록 출처 = 0.6

차단 = 0

즉, $\text{grade_score} < 0.6 \rightarrow$ 미등록보다 못한 출처 = 위험
 $\text{grade_score} = 0.6 \rightarrow$ 미등록(무명이지만 차단은 아님) = 주의
 $\text{grade_score} = 1.0 \rightarrow$ 티어1 통신사 = 안전

문서 예시가 **0.30을 "루머성"**이라고 했으니 이걸 기준점 삼고, 실무 관례(대략 "절반 이하면 못 믿는다")를 얹으면

$\text{source_trust} < 0.4 \rightarrow$ 루머 구간 (LLM이 내용 읽고도 못 믿겠다고 판단)

$0.4 \sim 0.7 \rightarrow$ 애매 (반박 약하게)

$\text{source_trust} \geq 0.7 \rightarrow$ 신뢰

grade (봉투)	trust (내용)	판정	반박
≥ 0.6	≥ 0.4	둘 다 좋음	통과
< 0.6	< 0.4	둘 다 나쁨	강한 반박 (명백 루머)
≥ 0.6	< 0.4	봉투만 좋음 📮	반박 (이름값 뒤 루머 - 제일 중요) 세계
< 0.6	≥ 0.4	내용만 좋음	약한 반박/통과

trust (내용) < 0.4 하면 공격형 느슨하게 설정을 해서 0.4이고/ 타이트하게 설정하면 0.5로 설정해야함.

but 봉투는 좋은데($\text{grade} \geq 0.6$) 내용이 루머인($\text{trust} < 0.4$)" 케이스 - 이걸 제일 세계 침그 이유는 실무에서 이게 제일 잘 속는 함정이거든 - "로이터가 보도했으니 팩트겠지" 하고 넘어갔다가 관측성 기사에 당하는 거. 공격형이라 문을 험겁게 여는 만큼, 이 한 구멍만큼은 꼭 막아두는 게 균형이 맞아서

④ 확신 캘리브레이션 = "저울이 정확한가"

개별 근거를 또 보는 게 아니라, *****종합했을 때 확신 숫자가 과한가*****를 보는것

confidence(확신)가 실제 근거에 맞게 매겨졌나

③ 미검증 촉매 = 뉴스 하나의 신뢰도를 봄 (이 촉매가 루머냐). 개별 근거의 질.

④ 확신 캘리브레이션 = 전체 확신(conviction) vs 전체 근거의 균형을 봄. 확신이 근거 대비 과한가.

④ 확신 캘리브레이션 — Layer 1 지시서

[④ 확신 캘리브레이션]

■ 1. 뭘 의심하는가

conviction(확신)이 실제 근거의 품질에 맞게 매겨졌나.

근거는 약한데 확신만 부풀려진(과신) 상태 아닌가.

■ 2. 뭘 보고 판단

- 은미: conviction(8.5), signal_consensus(동의 수)

- 원본(근거 품질): tb_news.source_trust·grade_score

tb_disclosure 유무·confidence

tb_technical.ml_probs(상승 확률)

→ "확신(위층)" vs "근거들(아래층)"을 대조

■ 3. 어떻게 따지나

높은 conviction(예: 8.0 ↑)을 주장하는데,

밑근거들이 그만큼 받쳐주나?

- source_trust가 낮은가? (촉매 부실)

- signal_consensus가 적은가? (동의 부족)

- 공시 없이 뉴스만인가? (근거 얕음)

- ml_probs 상승확률이 낮은가? (기술 약함)

→ 확신은 높는데 밑근거 다수가 약함 = 과신 = 반박

→ 확신에 걸맞게 근거도 튼튼 = 통과

■ 4. 뭐라고 답하나

"확신 캘리브레이션: [과신/적정]

근거: 예) conviction 8.5인데 source_trust 0.4·공시 없음·동의 2개

→ 근거 대비 확신 과함, 신뢰 하향 필요"

그래서

1,2,3,,번 하고 마지막 4번으로 종합해서생각함

[Layer 1 내부 구조 — B 방식]

1층 · 개별 공격 (원본 근거를 각자 직접 봄)

- ① 가짜 합의 → 결과
- ② 선반영·추격 → 결과
- ③ 미검증 촉매 → 결과
- ⑤ 신호 신선도 → 결과

↓ (네 개 결과를 모아서)

2층 · 종합 판정

- ④ 확신 캘리브레이션

"1층에서 이만큼 문제 나왔는데, conviction 8.5가 말이 되나?"

→ 최종 과신 여부

④ 확신 캘리브레이션 — B 방식 최종 지시서

[④ 확신 캘리브레이션 — 종합 판정 (2층)]

[④ 확신 캘리브레이션 — 종합 판정 (2층)]

■ 1. 뭘 의심하는가(선언)

- ①②③⑤에서 나온 문제들을 종합했을 때,
conviction(확신)이 과하게 높은가 (근거 대비 뻥튀기)

△ 제약 (반드시 지킬 것):

④는 개별 근거를 재차 감점하지 않는다.

오직 'conviction 숫자가 근거 총량에 맞게 매겨졌는가'만 판정한다.

→ ①②③⑤가 이미 깎은 것을 다시 깎지 않음 (이중 처벌 금지)

■ 2. 뭘 보고 판단

- 은미: conviction, signal_consensus
- 1층 결과: ①②③⑤ 각각의 반박 여부·강도

■ 3. 어떻게 따지나(실행시점 리마인드)

1층 반박의 개수·강도를 집계 → conviction 크기와 균형 저울질

- 강한 반박 여러 개인데 conviction 8.0 ↑ → 심한 과신
- 반박 거의 없는데 conviction 높음 → 적정

※ 개별 문제를 재처벌하는 게 아니라, 확신 숫자의 정확성만 본다

■ 4. 뭐라고 답하나

"확신 캘리브레이션: [과신/적정]

근거: 예) 강한 반박 2개 누적인데 conviction 8.5 → 확신 과함"

⑤ 신호 신선투 = "이 신호가 아직 싱싱하냐"

Layer 1 지시서

[⑤ 신호 신선투 (1층)]

■ 1. 뭘 의심하는가

판단 근거가 된 신호들이 아직 유효한가,
아니면 이미 낡아서(오래돼서) 지금 상황과 안 맞나

■ 2. 뭘 보고 판단

- 각 신호의 시각:
tb_news.collected_at, tb_disclosure.trade_date
tb_technical → "어제까지" 값 (구조적으로 하루 지연)
tb_macro.as_of (매크로 최신 행인가)
- 은미: current_price(실시간) vs tb_technical.close(어제종가) 괴리

■ 3. 어떻게 따지나

- 촉매(뉴스/공시)가 며칠 전 것인가? (오래될수록 김빠짐)
- 기술 신호(rsi 등)가 "어제 값"인데, 오늘 실시간가랑 크게 벌어졌나?
(current_price가 어제종가 대비 많이 움직였으면
→ 어제 기준 rsi-ret_5d는 이미 낡음)
- 매크로가 최신 행인가? (오래된 regime 읽고 있나)
→ 신호들이 낡았고 + 그새 상황이 변했으면 = 신선투 반박
→ 신호가 방금 것 or 상황 안 변함 = 통과

■ 4. 뭐라고 답하냐

"신호 신선투: [낡음/유효]"

근거: 예) rsi는 어제값 34(과매도)인데 오늘 +9% 급등,
지금은 과매도 아님 → 기술 신호 낡음"

★ 확인 (②⑤ 공통): tb_news/tb_disclosure의 시각 컬럼이 "실제 발생 시각"인지 "수집 시각"인지

— 신선투 판단의 정확성에 직결

Layer 2가 실제로 하는 일 — 3가지

ERD 이미지에 `tb_critic_verdict` 테이블 = Layer 2의 출력물 저장소

Layer 1이 5각도 결과를 뱉으면, Layer 2가 이걸 받아서:

1. 집계 (点数 매기기)

각 각도 결과를 숫자로 환산해서 합산.

예: ① 가짜합의 강한반박 = -3점

③ 이름값루머 강한반박 = -3점

④ 과신 = -2점

② 통과 = 0, ⑤ 통과 = 0

→ 총 반박 점수 -8점

2. 결정 (문턱 적용)

합산 점수가 정해진 문턱을 넘으면 reject, 아니면 pass.

예: 반박 점수 ≤ -5 점이면 → reject

-8점 → reject 확정

3. 기록 (결과 저장)

그 결정을 `tb_critic_verdict` 테이블에 저장. (ERD에서 봤던 그 테이블!)

decision: reject

category: 어느 각도에서 걸렸나

objection: 반박 이유

컬럼	뜻	Layer 2가 채움
<code>decision</code>	pass/reject	2단계 결정 결과
<code>agree</code>	동의 여부(BOOL)	은미 매수에 동의?
<code>category</code>	어느 각도 문제	걸린 각도
<code>objection</code>	반박 내용	LLM이 낸 이유
<code>confidence</code>	Critic 확신도	집계 점수 기반
<code>decided_layer</code>	몇 층에서 결정났나	0/1/2

"Layer 2 · 게이트(코드) — LLM을 그대로 안 믿고 임계값으로 통과/기각 확정. (공격형: 반박 $\text{confidence} \geq 0.70$ 이면 기각)"

이 숫자들 기준이 뭐냐

내가 묻은 거: "점수를 어떤 기준으로 매기냐? 업계에서 그렇게 하나?"

솔직하게 답할게. 완벽한 정답 숫자는 없어. 근데 아무렇게나 정하는 것도 아니야. 세 가지 근거로 정해져:

근거 1 — 업계 관행 (loose reference)

confidence 임계값을 0.7 근처에 두는 건 실무에서 흔해. 왜 0.7이냐면 — "웬만큼 확신할 때"의 심리적 기준선이거든. 0.5는 "반반"이라 너무 약하고, 0.9는 "거의 확실"이라 너무 빠세. 그 사이 "꽤 확신함"의 대표값이 0.7이야. 근데 이건 법칙이 아니라 관례야. 0.65든 0.75든 다 말이 돼.

근거 2 — 투자 성향 (이게 진짜 기준)

네 문서가 **공격형: ≥ 0.70** 이라고 꼭 집었지? 여기가 핵심이야. 임계값은 성향에 따라 움직여:

공격형 → 문턱 높게 (0.70). 반박이 어지간히 확실해야(0.7 이상) 기각. 애매하면 사증. = 매수 많이

보수형 → 문턱 낮게 (예: 0.5). 반박이 조금만 의심스러워도 기각. = 매수 적게

즉 0.70이라는 숫자 자체가 "우리는 공격형이다"의 표현이야. 성향을 숫자로 번역한 거지. 이건 우리가 계속 해온 거랑 똑같아 — trust 0.4도 "공격형이라 느슨하게"였잖아.

근거 3 — 백테스트 (최종 검증)

관행(0.7)과 성향(공격형)으로 일단 정한 다음, 과거 데이터로 돌려봐서 조정해. risk-off 70이 "백테스트로 튜닝"이었던 것처럼. "0.70으로 했더니 너무 많이 기각되네? 0.75로 올리자" 이런 식으로. 이게 숫자를 확정하는 마지막 단계야.

정리하면 — 숫자는 이렇게 정해져

숫자 정하는 3단계:

- ① 관행에서 출발 → confidence 0.7 근처가 "꽤 확신"의 표준
- ② 성향으로 조정 → 공격형이니 높게(0.70). 보수형이면 낮춰를 것
- ③ 백테스트로 확정 → 과거 데이터 돌려서 미세조정

"출발점은 업계 관행(0.7 근처)에서 빌려오지만, 최종 숫자는 '우리 성향(공격형) + 우리 데이터(백테스트)'로 정한다. 절대적 정답 숫자는 없고, 우리 시스템에 맞게 튜닝하는 것."

점수 매기기

먼저 헛갈리는 지점 정리 — confidence는 어디서 나오나네 문서(이미지 1)를 다시 정확히 보면:

Layer 1 (LLM): "agree · objection · confidence 산출" ← confidence를 여기서 만들어

Layer 2 (코드): "confidence ≥ 0.70 이면 기각" ← 그 confidence를 받아서 비교만 무슨 말이냐면 — confidence라는 숫자 자체는 Layer 1(LLM)이 뱉어. Layer 2(코드)는 그걸 0.70과 비교해서 pass/reject 도장만 찍어.그래서 네가 "2는 코드라 규칙으로"라고 한 건 절반 맞아:

Layer 2가 하는 일(0.70과 비교 → 기각)은 이미 규칙(코드)이야. ✔ 이걸 확정된 거. 근데 네가 아까 고민한 "confidence를 어떻게 매기냐"는 사실 Layer 1(LLM) 쪽 얘기였어

그래서 실무에서 많이 사용하는 방법인

Layer 1 (LLM): "agree · objection · confidence 산출" → LLM이 confidence를 제안

Layer 2 (코드): "LLM을 그대로 안 믿고 임계값으로 확정" → 코드가 검증/보정

즉 LLM이 초안을 내고, 코드가 감사하는 구조

[Layer 2 — 실무 표준 (단순 버전)]

1. LLM이 5각도 보고 confidence(0~1) 하나 낸다
(각도별 점수 계산 X, LLM이 종합해서 하나로)
2. 코드가 딱 두 개만 체크:
 - confidence가 0~1 범위인가? (기본 안전장치)
 - confidence ≥ 0.70 인가? → 기각 / 아니면 통과
3. 결과를 tb_critic_verdict에 저장

끝. 가중치표·보정규칙은 나중에 문제 생기면 추가.

그래서 **Layer 2 정리 (단순 버전)=일단 단순하게 시작하고, 문제 생기면 그때 정교화한다**

[Layer 2 · 게이트 — 확정]

입력: Layer 1(LLM)이 낸 confidence (0~1) + agree + objection

처리:

1. confidence 범위 체크 (0~1 벗어나면 오류)
2. confidence ≥ 0.70 → decision = "reject" (기각)
confidence < 0.70 → decision = "pass" (통과)

출력: tb_critic_verdict에 저장

decision, agree, category, objection, confidence, decided_layer

임계값 0.70 근거: 공격형(문턱 높게, 어지간히 확실해야 기각)
+ 나중에 백테스트로 튜닝

향후(문제 관찰 시): 코드 보정 규칙 하나씩 추가 → 1.5로 진화